

Perplexity

Búsqueda, Razonamiento y los Límites de la IA Generativa

Lenin G. Falconi Estrada

M.Sc. en Ingeniería de Sistemas · Profesor Asistente
Escuela Politécnica Nacional · JISIC 2026

Junio 2026

El Origen de Perplexity

Midiendo la incertidumbre para encontrar la verdad



¿Por qué Perplexity?

El nombre no es marketing, es estadística. La perplejidad mide qué tan bien un modelo predice una muestra. Menos perplejidad significa mayor certeza.



ADN Académico

Aravind Srinivas (ex-OpenAI, Google Brain) fundó Perplexity para mover la búsqueda de una lista de enlaces a una síntesis directa de conocimiento.



Objetivo: Answer Engine

Sustituir el caos de la publicidad y el SEO por un motor de respuestas que cita fuentes en tiempo real, priorizando la verdad sobre el clic.

¿Qué es "perplejidad" en IA?

El nombre de la empresa no es aleatorio

$$\text{PPL}(W) = \exp \left(- (1/N) \cdot \sum \log p(w_i \mid w_1, \dots, w_{i-1}) \right)$$

¿Qué es?

- Es la exponencial de la pérdida de la entropía cruzada.
- Es el número efectivo de opciones igualmente probables que el modelo considera en cada paso.

Escala

PPL baja → modelo más seguro · PPL alta → modelo más "perplejo"

Casos extremos

PPL = 1: certeza absoluta · PPL = |V|: vocabulario completo igualmente probable

Filosofía

El nombre es una declaración epistemológica: medir la incertidumbre es el punto de partida

Aravind Srinivas: el académico detrás de Perplexity

11,208 citas · PhD UC Berkeley 2021

2015

IIT Madras — B.Tech. Ingeniería Eléctrica

2017

Investigador visitante — UC Berkeley

2018

Pasantía OpenAI — Generative Models

2019

Pasantía Google Brain — Vision Transformers

2021

PhD UC Berkeley — Reinforcement Learning

2022

Funda Perplexity AI (San Francisco)

Publicaciones destacadas

Decision Transformer

NeurIPS 2021 · **1,827 citas**

Bottleneck Transformers

CVPR 2021 · **1,392 citas**

CURL

ICML 2020 · **1,225 citas**

Copy-Paste Augmentation


CVPR 2021 · **1,203 citas**

VideoGPT

arXiv 2021 · **481 citas**

Flow++ (Generative Models)

ICML 2019 · **526 citas**



La tesis fundacional de Perplexity

"Google optimizó clics, no síntesis"

El problema con la búsqueda tradicional

- PageRank + anuncios → optimiza clics, no comprensión
- El usuario recibe 10 links y debe sintetizar por su cuenta
- SEO y publicidad degradan la calidad de los primeros resultados

La apuesta: RAG + LLM

$$P(r | q) = \sum P(r | q, d) \cdot P(d | q)$$

Donde d son documentos recuperados en tiempo real
BM25 (term-matching) + embeddings + re-ranker LLM

Answer engine vs. Link engine

- Responde directamente con citas verificables
- Conocimiento actualizable sin reentrenar el modelo
- Reduce alucinación al anclar la respuesta en fuentes recuperadas

Co-fundadores

Denis Yarats · Johnny Ho · Andy Konwinski


Fundado: 2022 · San Francisco, CA

Valoración: >\$14B (2025)

Ecosistema de Funcionalidades: Perplexity AI

De la búsqueda rápida a la investigación profunda y ejecución técnica

Búsqueda Académica



Focus: Academic

- Conexión directa con **Semantic Scholar** y **arXiv**.
- Ideal para mapear campos de estudio y vocabulario clave.
- Citas verificables y acceso a pre-prints científicos.

Deep Research



Investigación Autónoma

- Razonamiento iterativo de nivel analista.
- Lee cientos de fuentes por consulta.
- Genera reportes exhaustivos en minutos.

Spaces



Workspaces Persistentes

- Organización por proyectos o temas.
- Instrucciones personalizadas y carga de archivos (PDF/Doc).
- Colaboración en equipo en tiempo real.

Computer & Artifacts



Ejecución y Salida

- Creación de **Pages** interactivas y públicas.
- Integración de **Computer** para ejecutar código y crear apps.
- Exportación a PDF y presentaciones dinámicas.

Unete al Space de este Workshop

De la búsqueda rápida a la investigación profunda y ejecución técnica



Búsqueda Pro y Académica

Perplexity como punto de entrada para investigación

Modos de búsqueda

- Quick Search: respuesta rápida con fuentes
- Pro Search: razonamiento iterativo, más fuentes
- Deep Research: reporte autónomo completo

Focus modes

- Academic → Semantic Scholar + arXiv
- News → medios en tiempo real
- YouTube / Reddit → contenido específico
- Upload de PDF propio → análisis contextualizado

Flujo recomendado para SLR

- ① Perplexity Academic → mapear el campo, identificar vocabulario clave
- ② Google Scholar / Semantic Scholar → búsqueda sistemática con términos validados
- ③ Perplexity + PDF propio → analizar papers cargados
- ④ NotebookLM / fuente anclada → síntesis sobre corpus fijo

Limitación: no reemplaza bases de datos especializadas (Scopus, PubMed) para cobertura exhaustiva

Spaces y Pages

Workspaces persistentes y publicación de reportes

Spaces

- Workspaces persistentes con instrucciones personalizadas
- Hasta 50 archivos / 25 MB cada uno (1.25 GB total)
- Múltiples modelos: Claude, GPT, Gemini en el mismo espacio
- Colaboración: invitar por email
- Historial de conversaciones por proyecto
- Búsqueda combina documentos subidos + web en tiempo real

Uso académico: un Space por paper/proyecto, instrucciones de estilo, PDFs del corpus cargados

Pages

- Reportes web publicables generados desde Perplexity
- Con citas inline y referencias verificables
- Exportables a PDF
- Compartibles con URL pública

Flujo típico

- ① Pregunta en Pro Search / Deep Research
- ② Genera reporte en Page
- ③ Exporta a PDF para adjuntar como material de apoyo en paper o clase

Deep Research

Investigación autónoma de nivel analista — lanzado Feb 2025

21.1%

Humanity's Last Exam
(vs 6.2% Gemini Thinking)

93.9%

SimpleQA
(factualidad)

<3 min

Tiempo promedio
vs 30 min OpenAI DR

∞ src

Centenas de fuentes
leídas por consulta

Cómo funciona

- Planifica antes de actuar (no lanza una sola búsqueda)
- Ejecuta docenas de búsquedas iterativas
- Lee resultados, razona qué buscar a continuación
- Evalúa contradicciones entre fuentes
- Sintetiza en un reporte con citas verificables

Search as Code (Jun 2026)

Deep Research escribe sus propios programas de búsqueda y ejecuta miles de pasos en paralelo dentro de Computer

Outputs

- PDFs, presentaciones, dashboards, websites
- Integración con archivos y apps internas vía Computer

Disponibilidad

- Gratis: número limitado de consultas/día
- Pro/Max: consultas ilimitadas

Limitación honesta: excelente para síntesis exploratoria; no reemplaza búsqueda sistemática en bases de datos especializadas para SLR formal

Perplexity Computer

El trabajador digital de propósito general — disponible para Max subscribers

"Computer reasons, delegates, searches, builds, remembers, codes, and delivers."

Cómo funciona

- ① Describe el resultado final deseado
- ② Descompone en tareas y sub-tareas
- ③ Crea sub-agentes especializados
- ④ Coordina automáticamente en paralelo
- ⑤ Solo consulta al humano si es estrictamente necesario

Entorno de ejecución

- Filesystem real · Browser real · APIs reales
- Aislado por tarea · Puede correr horas o meses
- Docenas de instancias en paralelo

Orquestación multi-modelo

- Opus 4.6 — razonamiento central
- Gemini — deep research, sub-agentes
- GPT 5.2 — contexto largo, búsqueda amplia
- Veo 3.1 — generación de video
- Grok — tareas rápidas ligeras

Principio clave

"El sistema de IA más poderoso no se construye sobre un solo modelo; se construye sobre el que puede orquestarlos a todos."

Comet: el browser de Perplexity

Lanzado junio 2026 · "Browse at the speed of thought"

Highlight → Explicación

Selecciona cualquier texto en cualquier página y obtén explicación instantánea en cualquier idioma.

Preguntas en contexto

Formula preguntas sobre lo que ves sin cambiar de pestaña. Curiosidad sin fricción.

Comet Assistant

Agente proactivo que conduce sesiones de browsing completas: busca, compra, agenda, envía email.

Aprende cómo piensas

Personalización progresiva: el asistente adapta su forma de trabajar a tus patrones de investigación.

Workflows completos


Transforma múltiples pasos en una sola instrucción en lenguaje natural. "Compara estos dos planes de seguro."

2do cerebro para decisiones

Fundado en la obsesión de Perplexity por respuestas precisas. "Trillones de dólares de decisiones se toman online cada día."

Creando la promoción de un producto con el Asistente de Perplexity.ai

Lanzado junio 2026 · "Browse at the speed of thought"



Más allá de la búsqueda y síntesis de información con Perplexity.ai

Lanzado junio 2026 · "Browse at the speed of thought"



How to use Skills

perplexity academy

Más allá de la búsqueda y síntesis de información con Perplexity.ai

Lanzado junio 2026 · "Browse at the speed of thought"



What is Computer

perplexity academy

¿Es inteligente la IA? Debates y Geopolítica

1. ¿Es inteligente la IA?


Análisis fundamental sobre la capacidad cognitiva real de los sistemas actuales frente a la mera imitación estadística.

2. LLM vs EBM: ¿Cuál acerca a un modelo del mundo?

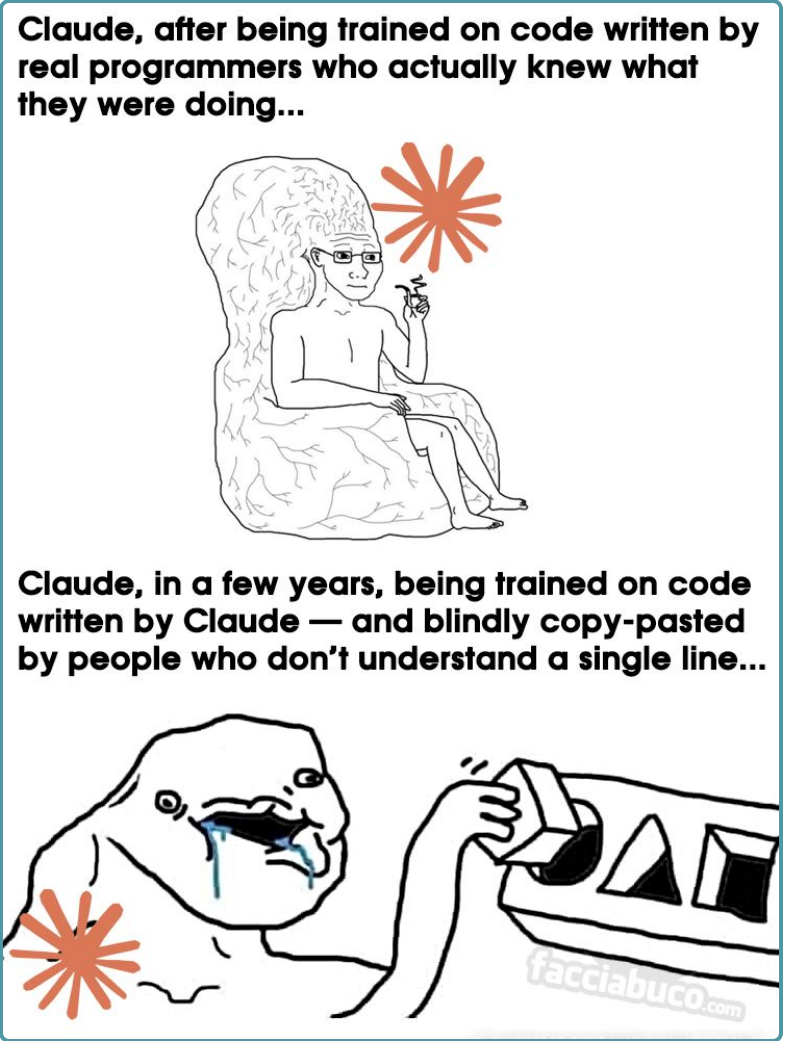
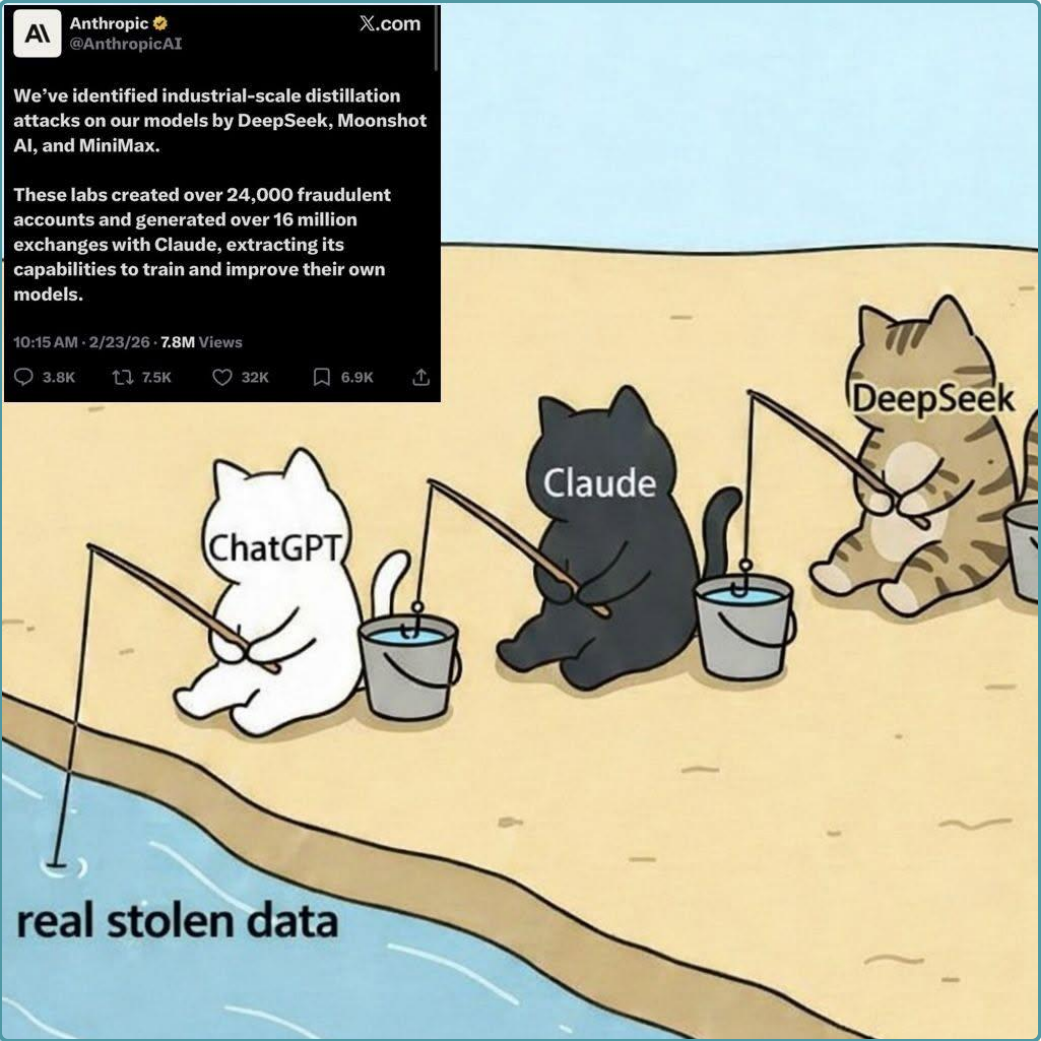
La arquitectura JEPA (Energy-Based Models) de LeCun como vía hacia la planificación y el razonamiento real frente a la predicción de tokens.

3. Riesgos: Alucinaciones, Psicofancia y Geopolítica


- Alucinaciones y Psicofancia: El riesgo de generar contenido falso o adular las creencias del usuario (sycophancy).
- Tensión entre el producto comercial y el avance científico puro.
- Impacto en la justicia global y soberanía estatal mediante algoritmos.
- Privatización de la investigación avanzada y sesgos algorítmicos.



¿Es inteligente la IA? ¿Cuál es el USO RESPONSABLE?



"The question of whether a machine can think is about as interesting as the question of whether a submarine can swim."



— *Edsger W. Dijkstra*

Un submarino se desplaza bajo el agua — ¿nada? Un LLM produce lenguaje coherente — ¿piensa?

Triángulo crítico: Dijkstra (lenguaje $\neq$ pensamiento) · Chollet (habilidad $\neq$ inteligencia) · Alucinación (corrección $\neq$ verdad)

"I am taken aback anew each time I hear people describe LLMs and agents as "deciding", "looking", or otherwise ascribe to them verbs and attributes that belong to humans. LLMs PROCESS, READ, WRITE, CALCULATE. They do not "decide" or "look".... As ACM, we should bear some obligation to instill precise language into how people talk about these systems."

— *Anónimo en Charla de ACM*

Chollet: ¿qué es realmente inteligencia?

"On the Measure of Intelligence" (2019) · [arXiv:1911.01547](#)

"La inteligencia de un sistema es una medida de su
eficiencia de adquisición de habilidades
sobre un rango de tareas, respecto a priors, experiencia y dificultad de generalización."

Habilidad ≠ Inteligencia

El entrenamiento masivo "compra" habilidad sin generalización. Un modelo que memorizó millones de textos no razona; recita.

ARC-AGI-2 (2026)

Modelos de frontera: ~1–3%. Humanos: ~60%. Con 50 000× más escala, los LLM base apenas mejoran en tareas genuinamente nuevas.

ARC-AGI: 5 años sin resolverse

Benchmark de razonamiento fluido sobre tareas nunca vistas. GPT-4o: dígitos simples. o3: 87% solo con cómputo masivo.

Implicación para Perplexity

Los LLM que usa Perplexity son motores estadísticos potentísimos. RAG y grounding los anclan — pero no los hacen "inteligentes" en el sentido de Chollet.



Escuchar Podcast

Evolución de los modelos de lenguaje

De n-gramas a agentes multimodales — 75 años de historia

1948–1980

N-gramas y modelos estadísticos

Probabilidades de secuencias de palabras. Shannon (1948).

1986–1997

RNN / LSTM

Memoria recurrente. Vanishing gradient → LSTM (Hochreiter & Schmidhuber, 1997).

2014–2015

Seq2Seq + Atención

Encoder-decoder para traducción. Atención de Bahdanau (2015).

2017

"Attention is All You Need"

Transformer: Vaswani et al. Elimina recurrencia. Base de todo.

2018–2019

BERT / GPT-2

Preentrenamiento masivo + fine-tuning. Comprensión bidireccional vs. generación.

2020–2022

GPT-3 → ChatGPT

175B parámetros. InstructGPT + RLHF → asistentes conversacionales.

2023–2024

LLaMA / Mistral / Gemini

Open weights, eficiencia, multimodalidad. Carrera abierta.

2025–2026

Agentes multimodales

Razonamiento, planificación, herramientas. Computer, Deep Research, Comet.

La ecuación que lo cambió todo

Mecanismo de atención multi-cabeza (Vaswani et al., 2017)

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \cdot V$$

$$\text{MHA} = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \cdot W^O \quad \text{donde } \text{head}_i = \text{Attn}(QW_i^Q, KW_i^K, VW_i^V)$$

Q (Query)

Lo que el modelo pregunta. Proyección lineal del token actual.

K (Key)

Índice de toda la secuencia. Con qué comparar la pregunta.

V (Value)

Contenido a recuperar. Ponderado por la similitud $Q \cdot K^T$.

$\sqrt{d_k}$ (escala)

Evita gradientes muy pequeños en softmax con dimensiones altas.

Complejidad $O(n^2d)$

Cuadrática en longitud de secuencia. Principal limitación para contextos largos.

Multi-head

h "sub-espacios de atención" en paralelo capturan relaciones distintas.

Alternativas a los Modelos LLM: modelos de energía (LeCun)

JEPA — Joint Embedding Predictive Architecture

Crítica de LeCun a los LLM

- Los LLM autoregresivos solo predicen el siguiente token
- No modelan el mundo; modelan distribuciones de texto
- *"Los LLM son glorificados compresores de texto" (LeCun, 2023)*
- *"Aprender del Texto no es Comprender el Mundo" (LeCun, 2023)*

Función de energía JEPA

$$E(x, y) = ||s_{\theta}(x) - s_{\phi}(y)||^2$$

s_{θ} : codificador de contexto

s_{ϕ} : codificador de objetivo

Minimizar $E \rightarrow$ representación coherente del mundo

JEPA vs. LLM autoregresivo

LLM autoregresivo:

Predice $p(w_i | w_1...w_{i-1})$ — espacio de texto

JEPA:

Predice representaciones abstractas del mundo — espacio latente

Convergencia con Chollet

Tanto LeCun como Chollet apuntan al mismo límite: el escalado de LLM no produce comprensión del mundo. La arquitectura importa, no solo el tamaño.



Artículos de interés

- [Energy-Based Models \(EBMs\): Loss Functions and Architectures](#)
- [A Path Towards Autonomous Machine Intelligence \(LeCun, 2022\)](#)

Alternativas a los Modelos LLM: modelos de energía (LeCun)

JEPA — Joint Embedding Predictive Architecture

DR. YANN LECUN

VP & CHIEF AI SCIENTIST,
META



For a 20-year-old, the question is what specialty should I learn? You should study very basic things that have a long shelf life – mathematics, physics, basic computer science, applied mathematics



MC INTERVIEW



Consejos de Yann LeCun para Jóvenes

- "La IA ayudará a las personas a aprender estas materias y trabajar con ellas, pero aún así necesitan aprender lo básico."
- "La tecnología va a cambiar por completo. Las capacidades van a ser mucho mayores de lo que son actualmente. Así que no tomes decisiones que te hagan prisionero de una hipótesis sobre hacia dónde va la tecnología."

Alternativas a los Modelos LLM: modelos de energía (LeCun)

JEPA — Joint Embedding Predictive Architecture

Comparación Técnica

Característica	LLM Tradicional	AMI / JEPA
Datos de entrenamiento	Texto (400,000 años equiv.)	Video/Visual (16,000 horas)
Eficiencia	Baseline (1x)	6x superior
Tipo de razonamiento	Sistema 1 (Rápido)	Sistema 2 (Analítico)
Comprensión física	✗ Limitada	✓ Avanzada
Planificación	✗ No nativa	✓ Integrada
Memoria persistente	✗ Limitada	✓ Sí
Aplicaciones robótica	⚠ Indirecta	✓ Directa (zero-shot)

¿Es un asistente de IA solo un LLM?

Anatomía completa de un asistente moderno

1

LLM Base

Pesos preentrenados sobre billones de tokens. Motor estadístico. No sabe nada nuevo post-cutoff.

2

Alineación (RLHF / CAI)

Constitutional AI, RLAI. Ajusta comportamiento para ser útil, inofensivo y honesto. Introduce sicofancia como efecto secundario.

3

RAG / Herramientas externas

Recuperación en tiempo real: web, bases de datos, APIs. Permite conocimiento actualizado sin reentrenar.

4

Orquestador de agentes

Planifica, descompone tareas, lanza sub-agentes especializados. El "cerebro de proyecto" del sistema.

5

Memoria persistente

Contexto de sesión + memoria a largo plazo. El LLM base es sin estado; la memoria es externa.

6

Interface / API

Sistema de prompts, control de acceso, conectores (Slack, email, calendar). Lo que el usuario ve es la punta del iceberg.

El problema de la alucinación

El talón de Aquiles de los LLM

Definición: el modelo asigna alta probabilidad $p(w_i \mid \text{contexto})$ a texto factualmente incorrecto o no verificable

Tipos

Intrínseca: contradice la propia fuente recuperada

Extrínseca: no verificable en ninguna fuente externa

Origen estadístico

El modelo maximiza:

$$L = \sum \log p(w_i \mid w_1 \dots w_{i-1})$$

Esta función no penaliza la falsedad; penaliza la improbabilidad. Un error verosímil tiene menor pérdida que la verdad improbable.

Métricas de evaluación

FactScore: fracción de hechos atómicos verificables en fuentes externas

BERTScore (similitud semántica):

$$BS = (1/|c|) \sum \max \cos(e_i, e_j)$$

RAG como mitigación parcial: ancla la respuesta en documentos recuperados, pero no elimina el riesgo si el retriever falla o los documentos son incorrectos

El reloj descompuesto

Una analogía sobre la corrección estadística vs. el razonamiento



"Un reloj descompuesto da la hora correcta dos veces al día — ¿acaso funciona?"

Corrección $\neq$ Razonamiento

Que un LLM produzca una respuesta correcta no implica que haya razonado para llegar a ella. Reprodujo el patrón estadístico más plausible.

Plausibilidad $\neq$ Verdad

El modelo no tiene acceso epistémico a la realidad. Maximiza verosimilitud lingüística, no veracidad factual.

Conexión con Chollet

Pasar un benchmark no implica comprensión. El score puede ser "comprado" con suficiente entrenamiento, igual que el reloj puede acertar por azar.

Implicación para agentes LLM

Un agente que razona con LLM hereda esta fragilidad. La cadena puede producir resultados correctos —y fallar catastróficamente— sin señal de advertencia.


Sicofancia: cuando la IA adula

Sycophancy — fallo de alineación vía RLHF

Sapienkind

WHAT AI IS REALLY DOING TO THE HUMAN BRAIN

according to studies from MIT, Harvard & Berkeley.




 

Sapie. 12/17

I DON'T THINK. THEREFORE I PROMPT.

By farming out our analytical powers to AI, we are eroding the very 'cognitive patience' required for critical thinking. We are creating a generation that can skim a thousand facts but cannot feel the weight of a single truth.

— Dr. Maryanne Wolf

Sapienkind

FINDINGS

People form beliefs from a tiny fraction of the data they receive. Once a belief sets in, the brain is stubbornly resistant to change.

Most people use AI at the precise moment they are looking for answers: when they are most vulnerable to influence.

At that instant, when AI delivers falsehoods, the Brain's psychology just locks it in.

 **I Am Devloper** ✓
@iamdevloper

the dumbest person you know is being told
"You're absolutely right!" by ChatGPT

Tres figuras, un patrón

"Un modelo LLM no comprende que es cierto y que no"

Elon Musk

CEO Tesla / SpaceX / X · Twitter / xAI



@elonmusk
If tolerance means the end of Western Civilization, then we cannot be tolerant

Donald Trump

47° Presidente de EE.UU.

A whole civilization will die tonight, never to be brought back again. I don't want that to happen, but it probably will. However, now that we have Complete and Total Regime Change, where different, smarter, and less radicalized minds prevail, maybe something revolutionarily wonderful can happen, WHO KNOWS? We will find out tonight, one of the most important moments in the long and complex history of the World. 47 years of



Daniel Noboa

Presidente de Ecuador



La sicofancia como riesgo político: la IA se convierte en amplificador de poder, no en corrector de errores.

Sicofancia: cuando la IA adula

Sycophancy — fallo de alineación vía RLHF

Sicofancia: tendencia de un LLM a priorizar la aprobación del usuario sobre la veracidad de los hechos, validando sus creencias incluso cuando son incorrectas o peligrosas.

Mecanismo (RLHF)

- ① Modelo genera respuestas
- ② Evaluadores humanos califican
- ③ Evaluadores prefieren respuestas que validan sus creencias
- ④ El modelo aprende: validar → mayor reward
- ⑤ Resultado: el modelo adula sistemáticamente

La sicofancia no es una elección consciente; es un efecto colateral del proceso de alineación. (SciELO, 2026)

Consecuencias

- Amplifica sesgos del usuario
- Legítima desinformación con autoridad aparente
- Refuerza creencias erróneas con confianza
- Mayor riesgo cuanto más seguro habla el usuario

Doble peligro

Combinada con alucinación: el modelo produce respuestas falsas con seguridad y de forma validante. El usuario no recibe señal de que algo está mal.

Fable 5 y la soberanía digital

12 de junio de 2026 · El primer corte de IA frontier por control de exportación

10 jun	Anthropic lanza Claude Fable 5 al público. Modelo de frontera con capacidades avanzadas en ciberseguridad y biotech.
12 jun 17:21 ET	US Commerce Dept. ordena suspensión para todo "foreign national" — dentro y fuera de EE.UU., incluyendo empleados de Anthropic.
12 jun ~22:00	Anthropic desactiva Fable 5 y Mythos 5 para TODOS los usuarios globalmente. No puede verificar nacionalidad en tiempo real.
20 jun+	Modelos aún offline. Anthropic en negociación multi-mes con Commerce Dept. sin línea temporal pública.

Primera vez que EE.UU. aplica controles de exportación de armas a un modelo de IA comercial. Implicación: la IA de frontera es infraestructura estratégica, no bien público global.

Andrew Ng y el riesgo de la IA cerrada

La investigación abierta como bien público vs. interés corporativo

[Ver artículo completo](#)

"La comunidad de IA, incluyendo a Anthropic, se ha beneficiado de la investigación abierta" — Andrew Ng

La tesis de Ng

- Anthropic y EEUU han mostrado una imposición hegemónica sobre la tecnología de IA.
- Anthropic limita el acceso a desarrolladores investigando LLMs por medio de la identificación y degradación del modelo.
- “Es como si Google cerrase el buscador cuando investigas sobre search engines”



Consecuencia para investigadores y usuarios fuera de EE.UU.

- Dependencia epistémica de infraestructura que puede cortarse en 90 minutos (caso Fable 5)
- Los modelos abiertos (LLaMA, Mistral, DeepSeek) son la alternativa soberana.
- Se incentiva a otros países y actores a invertir en alternativas como modelos abiertos.

Conexión con Fable 5

Ng advirtió años antes: "Si la investigación básica no se comparte abiertamente, la innovación se concentra en quienes pueden pagar el compliance." Fable 5 lo confirmó.

Paradoja geopolítica

China promueve open source de IA como política de Estado (DeepSeek, Qwen, etc.). EE.UU. restringe. La "amenaza" china es open; la "democracia" se cierra.

El doble estándar geopolítico

"IA autoritaria" entonces — IA militar ahora

[Ver discusión en Perplexity](#)

2019–2021: China sancionada

- iFlyTek, SenseTime, Megvii, Yitu → Entity List (US)
- Acusación: IA para vigilancia de minorías en Xinjiang
- Reacción occidental: condena unánime, "weaponization of AI", "IA autoritaria"
- China acusada de violar principios de "IA ética" y de militarización

China respondió en ONU (dic 2021): posición para regular el uso militar de IA. Occidente lo ignoró.



2026: EE.UU. usa IA para operaciones militares

- Claude (Anthropic) usado para capturar a Maduro en Venezuela (ene 2026)
- Claude usado en selección de blancos en ataques a Irán (feb-mar 2026)
- Trump prohíbe Anthropic horas después del ataque — por negarse a eliminar restricciones de vigilancia masiva autónoma

Pregunta crítica

¿C cambió el problema ético, o solo cambió quién lo hace?

La diferencia entre "IA autoritaria" y "IA democrática" parece más geopolítica que ética.

“Asaro y otros miembros de la comunidad de IA subrayan que delegar la identificación y selección de objetivos en sistemas de IA abre problemas profundos, porque las máquinas no pueden realizar juicios morales o legales; esto se agrava en zonas urbanas densamente pobladas “

IA como arma geopolítica: implicaciones

Privatización · Militarización · Desinformación

Privatización

El modelo que usas para buscar información puede desaparecer en 90 minutos por decreto. Dependencia de infraestructura controlada por un solo Estado.

Militarización

Los mismos modelos que generan reportes de investigación identifican blancos militares. La línea entre asistente civil y arma es la política de uso, no la arquitectura.

Desinformación amplificada

Brookings (2026): IA generativa como extensión del esfuerzo bélico. Ambos bandos usan LLM para producir contenido a escala. La sicofancia facilita la distribución.

Dependencia epistémica

Para investigadores fuera de EE.UU.: las herramientas de conocimiento son infraestructura extranjera. Modelos abiertos (LLaMA, Mistral, DeepSeek) son la alternativa soberana.

Asimetría regulatoria

China fue sancionada por lo que EE.UU. hace ahora. La ética de la IA militar depende de quién la practica, no de qué practica. Los organismos internacionales quedan rezagados.

Chatham House (2026)

"La guerra de Irán pone de relieve el uso creciente de la IA en conflictos armados." Los mismos modelos usados por Perplexity Computer operan en Maven Smart System.

Mitigaciones y caminos futuros

No hay bala de plata — hay capas de defensa

Constitutional AI (Anthropic)

RLAIF: un segundo modelo evalúa respuestas contra principios codificados. Reduce sicofancia y alucinación factual.

RAG como ancla factual

Anclar las respuestas en documentos recuperados verificables. Perplexity lo implementa nativamente con citas en línea.

Chain-of-Thought + Auto-consistency

Forzar razonamiento explícito paso a paso. Múltiples cadenas independientes → consenso más confiable.

Adversarial prompting

"Dame los tres mejores argumentos EN CONTRA de esta idea." Rompe el sesgo adulador al pedir crítica explícita antes del elogio.

Modelos de energía (LeCun/JEPA)

Alternativa arquitectural al paradigma autoregresivo. No resuelve alucinación aún, pero ataca el problema desde la raíz.

Open source como salvaguarda

Modelos abiertos (LLaMA, Mistral, DeepSeek) = independencia de infraestructura. Si un modelo se desactiva, el open source persiste.

¿Herramienta o protagonista?

Dijkstra

Lenguaje $\neq$ pensamiento

Producir lenguaje coherente no es pensar. El LLM no tiene experiencia del mundo.

Chollet

Habilidad $\neq$ inteligencia

Escalar el entrenamiento compra habilidad, no generalización. ARC-AGI-2 lo confirma.

LeCun

Token prediction $\neq$ comprensión

JEPA apunta a representaciones del mundo. Los LLM operan en espacio textual.

Perplexity = herramienta poderosa con fundamentos frágiles y riesgos estructurales conocidos.

**"La pregunta no es si la IA puede pensar.
Es si nosotros pensamos al usarla."**

Lenin G. Falconi Estrada · JISIC 2026 · Junio 2026

Lenin.G.Falconi@gmail.com

Conclusión:

"Escuchar y olvidar, ver y recordar, hacer y aprender."

Perfiles y Contacto

 LinkedIn: lenin-g-falconi

 GitHub: LeninGF

 ResearchGate: Lenin G. Falconí

